

# Redes Neurais Artificiais

*Introdução*



INFORMAÇÃO,  
TECNOLOGIA  
& INOVAÇÃO

# Introdução

- **Rede neural:** máquina desenvolvida para modelar a maneira com que o cérebro realiza uma tarefa. Neurônios artificiais conectados que passam por um processo de aprendizado .
- **Definição:** sistema de processamento massivamente paralelo e distribuído, construído com unidades de processamento simples, que tem uma propensão natural de armazenar conhecimento por meio de experiência e torná-lo disponível para uso.



# Introdução

Uma rede neural se assemelha a um cérebro em dois aspectos:

- Conhecimento é adquirido do ambiente pela rede por meio de um processo de aprendizado.
- As forças das conexões entre os neurônios, conhecidas como pesos sinápticos, são utilizadas para armazenar o conhecimento adquirido.



# Introdução

## Inspiração biológica:



- Replicar a função biológica
- Replicar a estrutura biológica



# Introdução

## Inspiração biológica:

- Replicar a função biológica
- Replicar a estrutura biológica



# Introdução

## Função do algoritmo de aprendizado?

- Tem como função modificar os pesos sinápticos da rede, de maneira a ajusta-los para cumprir o objetivo desejado
- Modificação dos pesos sinápticos: método tradicional de aprendizado
- Também é possível que uma rede modifique sua própria topologia durante o aprendizado
- Motivação: neurônios no cérebro humano morrem, e novas conexões são criadas



# Modelo de Neurônio

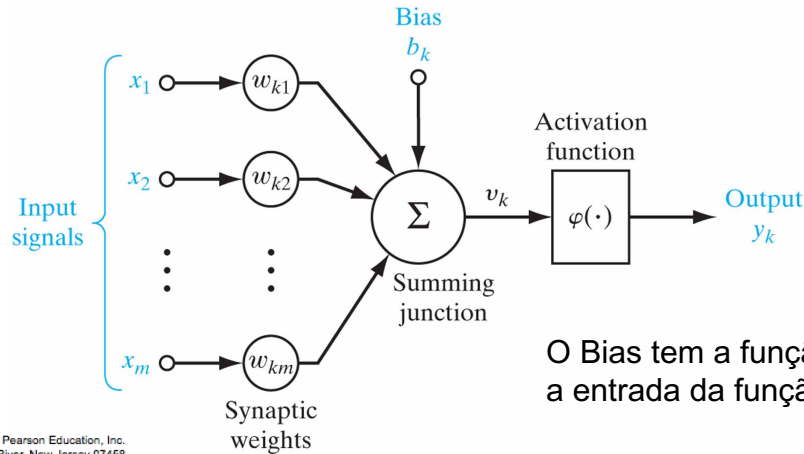
Neurônio: unidade de processamento de informação, fundamental para a operação da rede neural

- Conjunto de sinapses, cada uma caracterizada por um peso: um sinal  $x_j$  na entrada da sinapse  $j$  conectada ao neurônio  $k$ , é multiplicado pelo peso sináptico  $w_{kj}$ . Os valores dos pesos podem ser negativos ou positivos
- Um somatório, que faz a combinação linear das entradas (soma as entradas ponderadas pelos seus pesos sinápticos)
- Função de ativação, para limitar a amplitude da saída do neurônio. Tipicamente  $[0,1]$  ou  $[-1,1]$



# Modelo de Neurônio

Neurônio: unidade de processamento de informação, fundamental para a operação da rede neural



O Bias tem a função de aumentar ou diminuir a entrada da função de ativação



# Modelo de Neurônio

Matematicamente, descrevemos o neurônio  $k$  como:

$$u_k = \sum_{j=1}^m w_{kj} x_j \quad \text{e} \quad y_k = \varphi(u_k + b_k)$$

em que:

$x_1, x_2, \dots, x_m$  são sinais de entrada

$w_1, w_2, \dots, w_3$  são pesos sinápticos do neurônio  $k$

$u_k$  é a combinação linear das entradas

$b_k$  é o Bias

$\varphi(\cdot)$  é a função de ativação

$y_k$  é a saída do neurônio



# Modelo de Neurônio

- O uso do bias  $b_k$  tem o efeito de aplicar uma transformação em  $u_k$ , mantendo colinearidade

$$v_k = u_k + b_k$$


- Dependendo se  $b_k$  é positivo ou negativo, a relação entre o potencial de ativação  $v_k$  do neurônio  $k$ , e a saída da combinação linear  $u_k$ , é modificada
- O gráfico de  $v_k$  contra  $u_k$  não passa mais pela origem



# Modelo de Neurônio

O uso do bias  $b_k$  tem o efeito de aplicar uma transformação em  $u_k$ , mantendo colinearidade

$$v_k = u_k + b_k$$



# Modelo de Neurônio

- O bias  $b_k$  é um parâmetro externo do neurônio  $k$ . Ele pode ser incorporado à equação do neurônio

$$v_k = \sum_{j=0}^m w_{kj} x_j \quad \text{e} \quad y_k = \varphi(v_k)$$

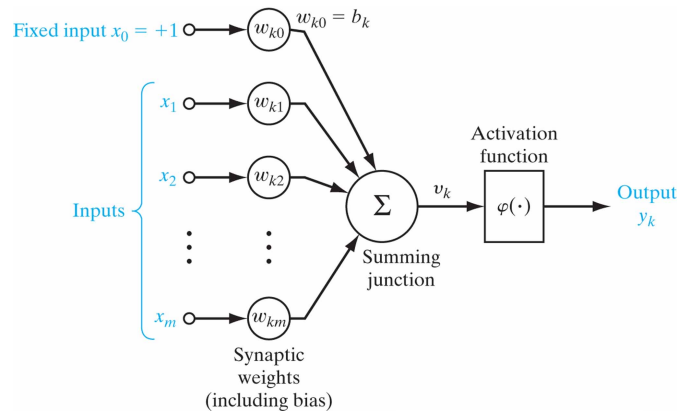
- Simplesmente foi adicionada uma entrada  $x_0$  com seu respectivo peso sináptico

$$x_0 = +1 \quad \text{e} \quad w_{k0} = b_k$$



# Modelo de Neurônio

O bias  $b_k$  é um parâmetro externo do neurônio  $k$ . Ele pode ser incorporado à equação do neurônio. Assim chegamos a um modelo matematicamente equivalente



Copyright ©2009 by Pearson Education, Inc.  
Upper Saddle River, New Jersey 07458  
All rights reserved.



# Funções de Ativação

- A função de ativação, denotada por  $\varphi(v)$ , define a saída do neurônio em termos de  $v$ :

$$\text{Função degrau: } \varphi(v) = \begin{cases} 1 & \text{se } v \geq 0 \\ 0 & \text{se } v < 0 \end{cases}$$

- A saída do neurônio  $k$  empregando essa função é dada por

$$y_k = \begin{cases} 1 & \text{se } v_k \geq 0 \\ 0 & \text{se } v_k < 0 \end{cases} \quad \text{sendo} \quad v_k = \sum_{j=1}^m w_{kj} x_j + b_k$$



# Funções de Ativação

$$\varphi(v) = \begin{cases} 1 & \text{se } v \geq 0 \\ 0 & \text{se } v < 0 \end{cases}$$

- Esse neurônio é conhecido como modelo de McCulloch-Pitts, devido ao trabalho de McCulloch e Pitts 1943
- A saída do neurônio é 1 se o potencial de ativação for positivo, e 0 caso contrário



# Arquiteturas de Redes Neurais

A maneira como os neurônios são estruturados (arquitetura da rede) tem relação direta em como a rede neural é treinada

- Redes neurais de uma camada
- Redes neurais de múltiplas camadas
- Redes neurais recorrentes






# Arquiteturas de Redes Neurais

## Redes neurais de uma camada

- Neurônios organizados em camadas
- Camada de entrada de dados conectada a uma camada de neurônios de saída



Copyright ©2009 by Pearson Education, Inc.  
Upper Saddle River, New Jersey 07458  
All rights reserved.



# Arquiteturas de Redes Neurais

## Redes neurais de múltiplas camadas


- Neurônios organizados em camadas
- Contém camadas escondidas atuam como extratores de estatísticas de mais alta ordem
- Neurônios de uma camada têm como entradas sinais provenientes apenas dos neurônios das camadas anteriores



# Arquiteturas de Redes Neurais

## Redes neurais de múltiplas camadas

- Neurônios organizados em camadas
- Podem ser totalmente ou parcialmente conectadas




Copyright ©2009 by Pearson Education, Inc.  
Upper Saddle River, New Jersey 07458  
All rights reserved.




# Arquiteturas de Redes Neurais

Múltiplas camadas - Regiões Convexas - Combinações de hiperplanos




# Arquiteturas de Redes Neurais

Múltiplas camadas – Combinações de regiões convexas




# Arquiteturas de Redes Neurais

Múltiplas camadas - Regiões Convexas - Combinações de hiperplanos



# Arquiteturas de Redes Neurais

Múltiplas camadas - Regiões Convexas - Combinações de hiperplanos



# Representação do Conhecimento

- **Conhecimento:** informação armazenada, ou modelos usados por uma pessoa ou máquina para interpretar, predizer, e responder apropriadamente ao mundo externo
- Boas soluções dependem de boas representações do conhecimento
- A rede neural deve aprender um modelo do mundo (ambiente) no qual ele está, e manter esse modelo consistente com o mundo real para realizar uma tarefa (alcançar um objetivo)





# Representação do Conhecimento

Conhecimento do mundo depende:

- 1. Conhecimento anterior: o estado do mundo, representado por fatos atuais e passados
- 2. Observações: obtidas por meio de sensores que sondam o ambiente no qual a rede neural vai operar

Observações podem conter ruído, devido a erros ou imperfeições na coleta. As observações coletadas são a fonte de informação, de onde se retirar os **exemplos** para treinar a rede neural.



# Representação do Conhecimento

Como o conhecimento é produzido para a rede neural?

- ***Exemplos similares de classes similares devem produzir representações similares dentro da rede, e devem portanto serem classificados numa mesma classe***
- Como medir similaridade?
- Distância Euclidiana:  $\mathbf{X}_i = [x_{i1}, x_{i2}, \dots, x_{im}]^T$



# Representação do Conhecimento

- O vetor  $\mathbf{x}_i = [x_{i1}, x_{i2}, \dots, x_{im}]^T$  define um ponto num espaço m-dimensional chamado espaço Euclidiano  $\mathfrak{R}^m$
- A **distância Euclidiana** entre  $\mathbf{x}_i$  e  $\mathbf{x}_j$  é definida como:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\| = \left[ \sum_{k=1}^m (x_{ik} - x_{jk})^2 \right]^{1/2}$$

- Quanto menor a distância Euclidiana, maior é a similaridade entre os vetores, portanto mesma classe



# Representação do Conhecimento

- Outra medida de similaridade: produto interno
- O **produto interno**  $\mathbf{x}_i^T \mathbf{x}_j$ , entre dois vetores de mesma dimensão é definido como a projeção do vetor  $\mathbf{x}_i$  no vetor  $\mathbf{x}_j$


$$(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j = \sum_{k=1}^m x_{ik} x_{jk}$$



# Representação do Conhecimento

- Essas duas medidas de similaridade são relacionadas. Quanto menor a distância Euclidiana, maior o produto interno
- Se normalizarmos os vetores, teremos  $\|\mathbf{x}_i\| = \|\mathbf{x}_j\|$

$$d^2(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i\|^2 + \|\mathbf{x}_j\|^2 - 2\mathbf{x}_i^T \mathbf{x}_j = 2 - 2\mathbf{x}_i^T \mathbf{x}_j$$



# Perguntas?

