

Redes Neurais Artificiais

Perceptron



INFORMAÇÃO,
TECNOLOGIA
& INOVAÇÃO

Perceptron




- A primeira rede neural descrita algoritmicamente
- Criado por Frank Rosenblatt, um psicólogo, e inspirou engenheiros, físicos e matemáticos a estudarem redes neurais
- O modelo proposto por Rosenblatt em 1958 como publicado em seu artigo, é válido até hoje

Perceptron

- A forma mais simples de uma rede neural utilizada para classificar padrões ditos **linearmente separáveis**
- Consiste de um único neurônio com pesos sinápticos ajustáveis e bias
- Rosenblatt desenvolveu o algoritmo para ajustar os parâmetros livres
- Rosenblatt provou que se os exemplos utilizados no treino pertencerem a classes linearmente separáveis, o algoritmo converge, posicionando um hiperplano entre as duas classes

Perceptron

- O Perceptron de Rosenblatt utiliza o modelo de neurônio de McCulloch-Pitts



Perceptron

- O Perceptron de Rosenblatt utiliza o modelo de neurônio de McCulloch-Pitts
- Os pesos sinápticos são denotados por w_1, w_2, \dots, w_m
- As entradas são denotadas por x_1, x_2, \dots, x_m
- O bias é denotado por b

$$v = \sum_{i=1}^m w_i x_i + b$$


Perceptron

- O objetivo do Perceptron é classificar corretamente um conjunto de exemplos denotados por x_1, x_2, \dots, x_m em uma de umas classes \mathcal{C}_1 ou \mathcal{C}_2
- O ponto representado por x_1, x_2, \dots, x_m é classificado como \mathcal{C}_1 se a saída y for $+1$ e como \mathcal{C}_2 se a saída y for -1 . Há duas regiões separadas por um **hiperplano**:


$$\sum_{i=1}^m w_i x_i + b = 0$$

Perceptron

- Ilustração de um hiperplano (linha reta) como fronteira de decisão para um problema de classificação com duas dimensões e duas classes
- Os pesos sinápticos são ajustados em um processo iterativo utilizando o algoritmo de convergência do Perceptron




Teorema de Convergência do Perceptron



- O bias $b(n)$ é tratado como um peso associado a uma entrada $+1$
- Vetor de entrada: $\mathbf{x}(n) = [+1, x_1(n), x_2(n), \dots, x_m(n)]^T$
- Vetor de pesos: $\mathbf{w}(n) = [b, w_1(n), w_2(n), \dots, w_m(n)]^T$

Teorema de Convergência do Perceptron

Copyright ©2009 by Pearson Education, Inc.
Upper Saddle River, New Jersey 07458
All rights reserved.





- O bias $b(n)$ é tratado como um peso associado a uma entrada $+1$
- Vetor de entrada: $\mathbf{x}(n) = [+1, x_1(n), x_2(n), \dots, x_m(n)]^T$
- Vetor de pesos: $\mathbf{w}(n) = [b, w_1(n), w_2(n), \dots, w_m(n)]^T$

$$v(n) = \sum_{i=0}^m w_i(n)x_i(n) = \mathbf{w}^T(n)\mathbf{x}(n)$$

Teorema de Convergência do Perceptron

Copyright ©2009 by Pearson Education, Inc.
Upper Saddle River, New Jersey 07458
All rights reserved.



- $\mathbf{w}^T \mathbf{x} = 0$ define um hiperplano de separação
- $\mathbf{w}^T \mathbf{x} > 0$ para todo vetor \mathbf{x} pertencente à classe \mathcal{C}_1
- $\mathbf{w}^T \mathbf{x} \leq 0$ para todo vetor \mathbf{x} pertencente à classe \mathcal{C}_2

Teorema de Convergência do Perceptron

- Se o n -ésimo vetor $\mathbf{x}(n)$ é corretamente classificado pelo vetor $\mathbf{w}(n)$ na n -ésima iteração do algoritmo, nenhuma correção é feita no vetor de pesos
 - ▣ $\mathbf{w}(n+1) = \mathbf{w}(n)$ se $\mathbf{w}^T \mathbf{x}(n) > 0$ e $\mathbf{x}(n)$ pertence a classe \mathcal{C}_1
 - ▣ $\mathbf{w}(n+1) = \mathbf{w}(n)$ se $\mathbf{w}^T \mathbf{x}(n) \leq 0$ e $\mathbf{x}(n)$ pertence a classe \mathcal{C}_2
- Caso contrário, o vetor de pesos é atualizado
 - ▣ $\mathbf{w}(n+1) = \mathbf{w}(n) - \eta(n)\mathbf{x}(n)$ se $\mathbf{w}^T(n)\mathbf{x}(n) > 0$ e $\mathbf{x}(n)$ pertence a classe \mathcal{C}_2
 - ▣ $\mathbf{w}(n+1) = \mathbf{w}(n) + \eta(n)\mathbf{x}(n)$ se $\mathbf{w}^T(n)\mathbf{x}(n) \leq 0$ e $\mathbf{x}(n)$ pertence a classe \mathcal{C}_1
- $\eta(n)$ é a taxa de aprendizado que controla o ajuste dos pesos

Teorema de Convergência do Perceptron

- A saída do neurônio é computada utilizando a função sinal $sgn(\cdot)$

$$sgn(v) = \begin{cases} +1 & \text{se } v > 0 \\ -1 & \text{se } v < 0 \end{cases}$$

- Expressamos a saída $y(n)$ de maneira compacta:

$$y(n) = sgn[\mathbf{w}^T(n)\mathbf{x}(n)]$$

Teorema de Convergência do Perceptron

TABLE 1.1 Summary of the Perceptron Convergence Algorithm

Variables and Parameters:

$\mathbf{x}(n)$ = $(m + 1)$ -by-1 input vector
= $[+1, x_1(n), x_2(n), \dots, x_m(n)]^T$

$\mathbf{w}(n)$ = $(m + 1)$ -by-1 weight vector
= $[b, w_1(n), w_2(n), \dots, w_m(n)]^T$

b = bias

$y(n)$ = actual response (quantized)

$d(n)$ = desired response

η = learning-rate parameter, a positive constant less than unity

1. *Initialization.* Set $\mathbf{w}(0) = \mathbf{0}$. Then perform the following computations for time-step $n = 1, 2, \dots$
2. *Activation.* At time-step n , activate the perceptron by applying continuous-valued input vector $\mathbf{x}(n)$ and desired response $d(n)$.
3. *Computation of Actual Response.* Compute the actual response of the perceptron as

$$y(n) = \text{sgn}[\mathbf{w}^T(n)\mathbf{x}(n)]$$

where $\text{sgn}(\cdot)$ is the signum function.

4. *Adaptation of Weight Vector.* Update the weight vector of the perceptron to obtain

$$\mathbf{w}(n + 1) = \mathbf{w}(n) + \eta[d(n) - y(n)]\mathbf{x}(n)$$

where

$$d(n) = \begin{cases} +1 & \text{if } \mathbf{x}(n) \text{ belongs to class } \mathcal{C}_1 \\ -1 & \text{if } \mathbf{x}(n) \text{ belongs to class } \mathcal{C}_2 \end{cases}$$

5. *Continuation.* Increment time step n by one and go back to step 2.

Teorema de Convergência do Perceptron

- No algoritmo de convergência, foi utilizada também a resposta desejada $d(n)$ para cada exemplo:

$$d(n) = \begin{cases} +1 & \text{se } \mathbf{x}(n) \text{ pertence à classe } \mathcal{C}_1 \\ -1 & \text{se } \mathbf{x}(n) \text{ pertence à classe } \mathcal{C}_2 \end{cases}$$



- A adaptação dos pesos ocorre de maneira elegante:

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \eta[d(n) - y(n)]\mathbf{x}(n)$$

- ▣ η : taxa de aprendizado
- ▣ $d(n) - y(n)$: sinal de erro


Teorema de Convergência do Perceptron

- Os pesos são corrigidos de acordo com o valor do produto interno $\mathbf{w}^T(\mathbf{x}(n))$
- Se o produto interno, na iteração n , tiver um sinal errado, os pesos devem ser ajustados para classificar o exemplo corretamente na iteração $n+1$



Como chegamos nisso?


$$E^2 = (d(n) - y(n))^2 = (d(n) - \mathbf{w}^T(n)\mathbf{x}(n))^2$$



Como chegamos nisso?


□ Gradiente Descendente: $w_i(n+1) = w_i(n) - \eta \frac{dE^2}{dw_i}$

$$\frac{dE^2}{dw_i} = \frac{d(d(n) - y(n))^2}{dw_i(n)} = 2 \times (d(n) - \mathbf{w}^T(n)\mathbf{x}(n)) \times -x_i$$



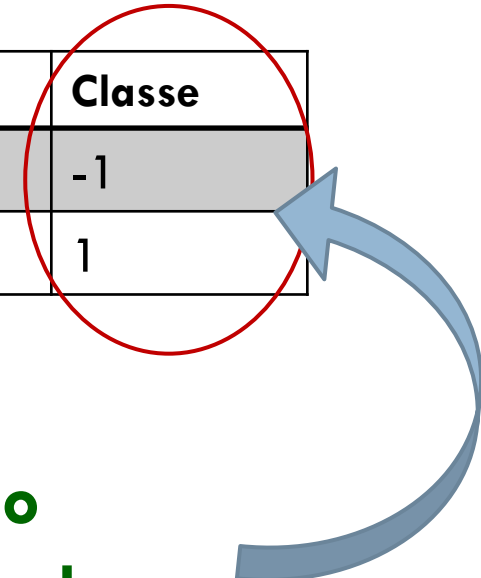
Exemplo

Dado	X1	X2	x3	Classe
E1	0	0	1	-1
E2	1	0	0	1



Exemplo


Dado	x1	x2	x3	Classe
E1	0	0	1	-1
E2	1	0	0	1



**Aprendizado
supervisionado**

$$f(X) = \begin{cases} 1 & \text{se } X \geq 0 \\ -1 & \text{se } X < 0 \end{cases}$$


Primeira Época



$$X = (-1 * 0,5) + (0 * 0,4) + (0 * -0,5) + (1 * 0,6) = 0,1$$


$$f(0,1) = 1$$

$$e = -1 - 1 = -2$$




$$w_{0\text{--}novo} = w_{0\text{--}anterior} + (\eta * \text{erro} * x_0) =$$

$$= 0,5 + 0,8 = 1,3$$




$$w_{1\text{--}novo} = w_{1\text{--}anterior} + (\eta * \text{erro} * x_1) =$$

$$= 0,4$$




$$\begin{aligned}
 w_{3\text{--}novo} &= w_{3\text{--}anterior} + (\eta * \text{erro} * x_3) = \\
 &= 0,6 - 0,8 \\
 &= -0,2
 \end{aligned}$$



$$X = (-1 * 1,3) + (1 * 0,4) + (0 * -0,5) + (0 * -0,2) = -0,9$$


$$f(-0,9) = -1$$

$$e = 1 - (-1) = 2$$




$$w_{0_novo} = w_{0_anterior} + (\eta * \text{erro} * x_0) =$$

$$= 1,3 - 0,8 = 0,5$$



$$\begin{aligned}
 w_{1\text{—}novo} &= w_{1\text{—}anterior} + (\eta * \text{erro} * x_0) = \\
 &= 0,4 + 0,8 = 1,2
 \end{aligned}$$

Segunda Época




$$X = (-1 * 0,5) + (0 * 1,2) + (0 * -0,5) + (1 * -0,2) = -0,7$$

$$f(-0,7) = -1$$

$$e = -1 - (-1) = 0$$

Segunda Época




$$X = (-1 * 0,5) + (1 * 1,2) + (0 * -0,5) + (0 * -0,2) = 0,7$$

$$f(0,7) = 1$$

$$e = 1 - 1 = 0$$


Rede final




Não ocorreram erros durante a última época.

Classificação

Dado	X1	X2	x3	Classe
E1	1	1	1	?
E2	1	1	0	?
E3	0	1	1	?




Classificação



$$X = (-1 * 0,5) + (1 * 1,2) + (1 * -0,5) + (1 * -0,2) = 0$$

$$f(0) = \mathbf{1}$$


Classificação



$$X = (-1 * 0,5) + (1 * 1,2) + (1 * -0,5) + (0 * -0,2) = 0,2$$

$$f(0,2) = \mathbf{1}$$

Classificação




$$X = (-1 * 0,5) + (0 * 1,2) + (1 * -0,5) + (1 * -0,2) = -1,2$$

$$f(-1,2) = -1$$

Classificação

Dado	X1	X2	x3	Classe
E1	1	1	1	1
E2	1	1	0	1
E3	0	1	1	-1



Perguntas?

